Physics Informed Neural Networks(PINNs): résolution d'équations différentielles

Charmant BALOGOUN, élève-ingénieur en Génie Mathématique et Modélisation

20 mars 2026

Table des matières

1 Introduction **2**

2 Fondements mathématiques des PINNs **2**
2.1 Concept . . . 2
2.2 Formulation . . . 2
2.3 Fonction de perte . . . 3
2.4 Optimisation . . . 3
2.5 Avantages et limites : . . . 3

3 Applications **4**
3.1 Mouvement d'un projectile . . . 4
3.1.1 Equations du mouvement . . . 4
3.1.2 Solution analytique . . . 4
3.1.3 Construction du PINN . . . 4
3.1.4 Implémentation et résultats . . . 5
3.2 Système masse-ressort . . . 6
3.2.1 Equations du mouvement . . . 6
3.2.2 Solution analytique . . . 6
3.2.3 Construction du PINN . . . 7
3.2.4 Implémentation et résultats . . . 7
3.3 Modèle épidémiologique SIR . . . 8
3.3.1 Équations du modèle SIR . . . 8
3.3.2 Construction du PINN . . . 9
3.3.3 Implémentation et résultats . . . 10

4 Conclusion **11**

1 Introduction

Les réseaux neuronaux informés par la physique (PINNs-Physics-informed neural networks), également appelés réseaux neuronaux guidés par la théorie (TTN) sont des d'algorithmes d'apprentissage automatique qui intégrent la connaissance de lois physiques dans le processus d'entraînement. Souvent, ces lois physiques prennent la forme d'équations aux dérivées partielles (EDPs). L'utilisation de telles contraintes physiques a pour objectif de guider l'apprentissage du modèle pour en améliorer les performances. Cela est particulièrement utile quand la faible disponibilité des données limite la robustesse des modèles d'apprentissage automatique conventionnels, ce qui est parfois le cas pour certains problèmes biologiques et d'ingénierie. Dans ce document, nous présentons les fondements mathématiques des PINNs ainsi que leur application dans la résolution de trois modèles : mouvement d'un projectile, système masse-ressort, et modèle épidémiologique SIR.

2 Fondements mathématiques des PINNs

2.1 Concept

Les PINNs sont utilisés pour approcher les solutions des EDP/EDO en incorporant les lois physiques directement dans la fonction de perte. En effet, au lieu d'utiliser les méthodes classiques de résolution numériques, ici on cherche une fonction $u(x,t;\theta)$ paramétrée par un réseau de neurones qui satisfait l'équation différentielle et respecte les conditions initiales et aux limites.

2.2 Formulation

Soit $x \in \Omega$, $t \in [0,T]$. Soit une équation différentielle de la forme :

$$\mathcal{F}[u](x,t) = f(x,t) \quad \text{dans } \Omega \times [0,T] \tag{1}$$

avec :

— $\Omega \subset \mathbb{R}^n$

— $t \in [0,T]$

— $\mathcal{F}$ un opérateur différentiel ($\frac{\partial u}{\partial t}, \frac{\partial u}{\partial x}$, $\frac{\partial^2 u}{\partial x^2}$, etc.)

— $u(x,t)$ la fonction solution

Considérons les conditions initiales et aux limites suivantes :

$$u(x,0) = u_0(x) \quad \text{pour } x \in \Omega \tag{2}$$

$$\mathcal{B}[u](x,t) = g(x,t) \quad \text{pour } x \in \partial\Omega,\ t \in [0,T] \tag{3}$$

avec $\mathcal{B}$ un opérateur différentiel.

Pour résoudre cette équation, on définit un réseau de neurones $\hat{u}(x,t;\theta)$ avec les paramètres θ qui approche la solution $u(x,t)$:

$$\hat{u} : \mathbb{R}^n \times \mathbb{R} \to \mathbb{R}^m, \quad (x,t) \mapsto \hat{u}(x,t;\theta) \tag{4}$$

Pour un réseau de neurones simple, l'apprentissage est faite sur les données et le modèle est de plus en plus performant lorsqu'on minimise la fonction de perte(Loss function). Ainsi pour apprendre à ce réseau les lois de la physique, on ajoute à la perte sur les données, les pertes sur résidu de l'EDP, conditions initiales et conditions aux limites.

2.3 Fonction de perte

La fonction de perte du PINN est la suivante :

$$\mathcal{L}(\theta) = \lambda_r \mathcal{L}_r(\theta) + \lambda_{ic}\mathcal{L}_{ic}(\theta) + \lambda_{bc}\mathcal{L}_{bc}(\theta) + \lambda_{data}\mathcal{L}_{data}(\theta) \tag{5}$$

avec :
$\mathcal{L}_r$:Perte sur le résidu de l'EDP
$\mathcal{L}_{ic}$:Perte sur les conditions initiales
$\mathcal{L}_{bc}$:Perte sur les conditions aux limites
$\mathcal{L}_{data}$:Perte sur les données
$\lambda_r, \lambda_{ic}, \lambda_{bc}, \lambda_{data}$:Coefficients de pondération

$$\mathcal{L}_r(\theta) = \frac{1}{N_r}\sum_{i=1}^{N_r} |\mathcal{F}[\hat{u}](x_i, t_i) - f(x_i, t_i)|^2 \tag{6}$$

où $\{(x_i, t_i)\}_{i=1}^{N_r}$ sont des **points de collocation** choisis dans le domaine $\Omega \times [0, T]$.

$$\mathcal{L}_{ic}(\theta) = \frac{1}{N_{ic}}\sum_{i=1}^{N_{ic}} |\hat{u}(x_i, 0) - u_0(x_i)|^2 \tag{7}$$

$$\mathcal{L}_{bc}(\theta) = \frac{1}{N_{bc}}\sum_{i=1}^{N_{bc}} |\mathcal{B}[\hat{u}](x_i, t_i) - g(x_i, t_i)|^2 \tag{8}$$

Si on a des observations $\{(x_j, t_j, u_j)\}$:

$$\mathcal{L}_{data}(\theta) = \frac{1}{N_{data}}\sum_{j=1}^{N_{data}} |\hat{u}(x_j, t_j) - u_j|^2 \tag{9}$$

Pour calculer $\mathcal{F}[\hat{u}]$, on a besoin des dérivées de $\hat{u}$ par rapport à x et t. On utilise la **différentiation automatique** pour les calculer :

$$\frac{\partial \hat{u}}{\partial t}, \quad \frac{\partial \hat{u}}{\partial x}, \quad \frac{\partial^2 \hat{u}}{\partial x^2}, \quad \text{etc.}$$

2.4 Optimisation

La minimisation de la loss function $\mathcal{L}(\theta)$ est faite par l'algorithme de la descente de gradient :

$$\theta^{(k+1)} = \theta^{(k)} - \alpha \nabla_\theta \mathcal{L}(\theta^{(k)}) \tag{10}$$

2.5 Avantages et limites :

Les PINNs présentent une flexibilité géométrique(pas besoin de maillage contrairement aux différences finies, éléments finies, etc). Ils compensent la faible quantité des données par les lois physiques et peuvent permettre d'estimer des paramètres. En revanche, les coefficients de pondérations sont choisit et ajuster au cours de l'apprentissage, ce qui représente un défi. De plus l'entraînement est long pour les EDP complexes.

3 Applications

Pour les applications suivantes, nous n'utiliserons pas des données. Donc il n'y a pas le terme $\lambda_{data}\mathcal{L}_{data}(\theta)$.

3.1 Mouvement d'un projectile

Un projectile de masse m est lancé depuis une position (x_0, y_0) avec une vitesse initiale v_0 et un angle θ_0 par rapport à l'horizontale. L'objectif est de déterminer la position $(x(t), y(t))$ de ce projectile à tout instant t. Les forces de frottement sont négligeables et $g = 9.81m/s$.

3.1.1 Equations du mouvement

A $t = 0$ on a :

$$x(0) = x_0 \tag{11}$$
$$y(0) = y_0 \tag{12}$$
$$\frac{dx}{dt}(0) = v_x(0) = v_0 \cos\theta_0 \tag{13}$$
$$\frac{dy}{dt}(0) = v_y(0) = v_0 \sin\theta_0 \tag{14}$$

$\forall t$,

$$\frac{d^2x}{dt^2} = 0 \tag{15}$$
$$\frac{d^2y}{dt^2} = -g \tag{16}$$

3.1.2 Solution analytique

Positions

$$x(t) = x_0 + v_0 \cos\theta_0 \cdot t \tag{17}$$
$$y(t) = y_0 + v_0 \sin\theta_0 \cdot t - \frac{1}{2}gt^2 \tag{18}$$

Vitesses

$$v_x(t) = v_0 \cos\theta_0 \tag{19}$$
$$v_y(t) = v_0 \sin\theta_0 - gt \tag{20}$$

Equation de la trajectoire

$$y = y_0 + \tan\theta_0 \cdot (x - x_0) - \frac{g}{2v_0^2 \cos^2\theta_0} \cdot (x - x_0)^2 \tag{21}$$

3.1.3 Construction du PINN

Entrée : $t \in [0, T_{max}]$
Sortie : $\begin{pmatrix} \hat{x}(t;\theta) \\ \hat{y}(t;\theta) \end{pmatrix}$
Vitesses (calculées par différentiation automatique) :

$$\hat{v}_x(t;\theta) = \frac{\partial \hat{x}}{\partial t}(t;\theta) \tag{22}$$
$$\hat{v}_y(t;\theta) = \frac{\partial \hat{y}}{\partial t}(t;\theta) \tag{23}$$

Accélérations (calculées par différentiation automatique) :

$$\hat{a}_x(t;\theta) = \frac{\partial^2 \hat{x}}{\partial t^2}(t;\theta) \tag{24}$$

$$\hat{a}_y(t;\theta) = \frac{\partial^2 \hat{y}}{\partial t^2}(t;\theta) \tag{25}$$

Perte physique
Résidus :

$$r_x(t_i) = \frac{\partial^2 \hat{x}}{\partial t^2}(t_i;\theta) - 0 = \frac{\partial^2 \hat{x}}{\partial t^2}(t_i;\theta) \tag{26}$$

$$r_y(t_i) = \frac{\partial^2 \hat{y}}{\partial t^2}(t_i;\theta) - (-g) = \frac{\partial^2 \hat{y}}{\partial t^2}(t_i;\theta) + g \tag{27}$$

$$\mathcal{L}_{physics}(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} \left[r_x^2(t_i) + r_y^2(t_i) \right] \tag{28}$$

$$\mathcal{L}_{physics}(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} \left[\left(\frac{\partial^2 \hat{x}}{\partial t^2} \right)^2 + \left(\frac{\partial^2 \hat{y}}{\partial t^2} + g \right)^2 \right] \tag{29}$$

Perte sur les conditions initiales
On impose les 4 conditions initiales à $t = 0$:

$$\mathcal{L}_{ic}(\theta) = [\hat{x}(0;\theta) - x_0]^2 + [\hat{y}(0;\theta) - y_0]^2 + \left[\frac{\partial \hat{x}}{\partial t}(0;\theta) - v_0 \cos\theta_0 \right]^2 + \left[\frac{\partial \hat{y}}{\partial t}(0;\theta) - v_0 \sin\theta_0 \right]^2$$

Perte totale

$$\mathcal{L}(\theta) = \lambda_{phys} \cdot \mathcal{L}_{physics}(\theta) + \lambda_{ic} \cdot \mathcal{L}_{ic}(\theta) \tag{30}$$

où λ_{phys} et λ_{ic} sont des coefficients de pondération (hyperparamètres).
On cherche les paramètres θ^* qui minimisent la perte totale :

$$\theta^* = \min_{\theta} \mathcal{L}(\theta) \tag{31}$$

3.1.4 Implémentation et résultats

Les paramètres physiques sont $g = 9{,}81$ m/s^2, $v_0 = 20$ m/s et $\theta = 45$. Le réseau est entraîné avec l'optimiseur Adam (taux d'apprentissage $\alpha = 10^{-3}$) pendant 10 000 époques. Les coefficients de pondération sont $\lambda_{\text{phys}} = 1{,}0$ et $\lambda_{\text{ic}} = 5{,}0$.

Hyperparamètre	**Valeur**	**Description**
Couches cachées	3	nombre de couches
Neurones/couche	32	largeur du réseau
Activation	Tanh	
N_r	200	points de collocation
α	10^{-3}	taux d'apprentissage
Époques	10 000	
λ_{phys}	1,0	poids résidu physique
λ_{ic}	5,0	poids conditions initiales

TABLE 1 – Hyperparamètres du PINN

La figure 1 présente la trajectoire prédite par le PINN comparée à la solution analytique, ainsi que l'évolution temporelle de $x(t)$ et $y(t)$ et les erreurs absolues. Les erreurs maximales obtenues sont :

$$\max_t |\hat{x}(t) - x_{\text{exact}}(t)| \approx 0{,}020 \text{ m}, \qquad \max_t |\hat{y}(t) - y_{\text{exact}}(t)| \approx 0{,}019 \text{ m}, \tag{32}$$

soit moins de 0,1 % de la portée maximale ($x_{\max} \approx 40{,}8$ m). Ces résultats valident l'approche PINN pour ce problème à deux degrés de liberté.

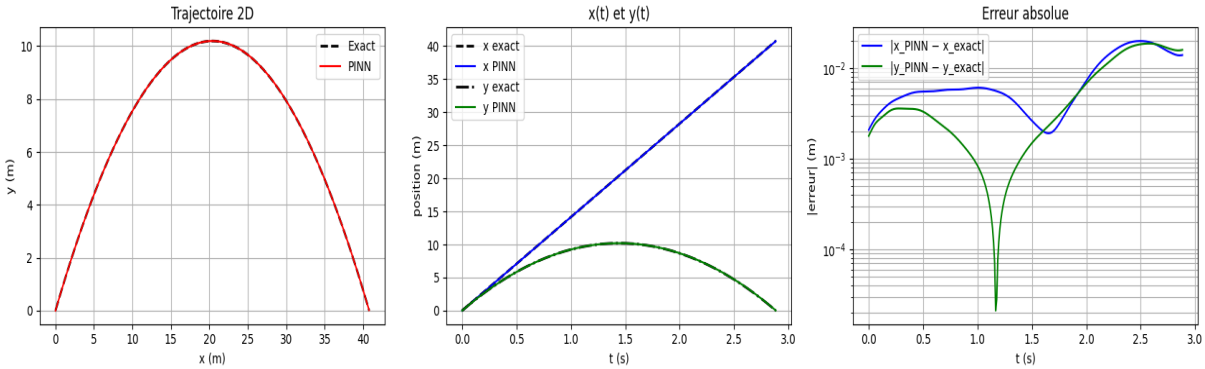


FIGURE 1 – projectile ($v_0 = 20$ m/s, $\theta = 45$). (1. trajectoire dans le plan. 2. $x(t)$ et $y(t)$. 3. erreurs absolues).

3.2 Système masse-ressort

Une masse m est attachée à un ressort de raideur k, avec un amortisseur de coefficient c. On tire la masse à une position x_0 puis on la lâche avec une vitesse v_0. On veut déterminer la position $x(t)$ de cette masse à tout instant t.

3.2.1 Equations du mouvement

A $t = 0$ on a :

$$x(0) = x_0 \tag{33}$$

$$\frac{dx}{dt}(0) = v(0) = v_0 \tag{34}$$

$\forall t$,

$$m\frac{d^2x}{dt^2} + c\frac{dx}{dt} + kx = 0 \tag{35}$$

Forme canonique :

En divisant par m on a :

$$\frac{d^2x}{dt^2} + 2\zeta\omega_0\frac{dx}{dt} + \omega_0^2 x = 0 \tag{36}$$

où :

$$\omega_0 = \sqrt{\frac{k}{m}} \quad \text{(pulsation propre)} \tag{37}$$

$$\zeta = \frac{c}{2\sqrt{km}} \quad \text{(coefficient d'amortissement)} \tag{38}$$

Cas particuliers selon ζ

— $\zeta = 0$: **Non amorti** (oscillations sinusoïdales)
— $0 < \zeta < 1$: **Sous-amorti** (oscillations décroissantes)
— $\zeta = 1$: **Critique** (retour rapide sans oscillation)
— $\zeta > 1$: **Sur-amorti** (retour lent sans oscillation)

3.2.2 Solution analytique

Nous allons considérer le cas sous-amorti $0 < \zeta < 1$. **Pulsation amortie :**

$$\omega_d = \omega_0\sqrt{1-\zeta^2} \tag{39}$$

$$x(t) = e^{-\zeta\omega_0 t}\left[x_0\cos(\omega_d t) + \frac{v_0 + \zeta\omega_0 x_0}{\omega_d}\sin(\omega_d t)\right] \tag{40}$$

3.2.3 Construction du PINN

Entrée : $t \in [0, T_{max}]$
Sortie : $\hat{x}(t;\theta)$
Vitesse (calculée par différentiation automatique) :

$$\hat{v}(t;\theta) = \frac{d\hat{x}}{dt}(t;\theta) \tag{41}$$

Accélération (calculée par différentiation automatique) :

$$\hat{a}(t;\theta) = \frac{d^2\hat{x}}{dt^2}(t;\theta) \tag{42}$$

Perte physique
Résidu :

$$r(t_i) = m\frac{d^2\hat{x}}{dt^2} + c\frac{d\hat{x}}{dt} + k\hat{x} \tag{43}$$

$$\mathcal{L}_{physics}(\theta) = \frac{1}{N_r}\sum_{i=1}^{N_r} r^2(t_i) \tag{44}$$

Perte sur les conditions initiales

$$\mathcal{L}_{ic}(\theta) = \left[\hat{x}(0;\theta) - x_0\right]^2 + \left[\frac{d\hat{x}}{dt}(0;\theta) - v_0\right]^2 \tag{45}$$

Perte totale

$$\mathcal{L}(\theta) = \lambda_{phys} \cdot \mathcal{L}_{physics}(\theta) + \lambda_{ic} \cdot \mathcal{L}_{ic}(\theta) \tag{46}$$

où λ_{phys} et λ_{ic} sont des coefficients de pondération (hyperparamètres).
On cherche les paramètres θ^* qui minimisent la perte totale :

$$\theta^* = \min_{\theta} \mathcal{L}(\theta) \tag{47}$$

3.2.4 Implémentation et résultats

Les paramètres physiques sont $m = 1{,}0$ kg, $k = 2{,}0$ N/m, $c = 0{,}4$ N·s/m et $x_0 = 1{,}0$ m, ce qui donne un régime sous-amorti avec $\zeta \approx 0{,}141$ et $\omega_d \approx 1{,}400$ rad/s. L'entraînement utilise l'optimiseur Adam avec un planificateur StepLR (réduction du taux par un facteur $\gamma = 0{,}1$ toutes les 3000 époques) pendant 40 000 époques. Les coefficients de pondération sont $\lambda_{\text{phys}} = 100{,}0$ et $\lambda_{\text{ic}} = 1000{,}0$.

Hyperparamètre	**Valeur**	**Description**
Couches cachées	8	nombre de couches
Neurones/couche	64	largeur du réseau
Activation	Tanh	
N_r	200	points de collocation
α_0	10^{-3}	taux d'apprentissage initial
Planificateur	StepLR	$\Delta = 3000$, $\gamma = 0{,}1$
Époques	40 000	
λ_{phys}	100,0	poids résidu physique
λ_{ic}	1000,0	poids conditions initiales

TABLE 2 – Hyperparamètres du PINN

La figure 2 compare le déplacement prédit par le PINN à la solution analytique et montre l'erreur absolue. Le PINN reproduit avec précision l'oscillation amortie sur toute la fenêtre temporelle. L'erreur absolue reste comprise entre 10^{-6} m et 3×10^{-4} m, ce qui confirme la capacité du réseau à capturer simultanément l'enveloppe exponentielle et la phase oscillatoire.

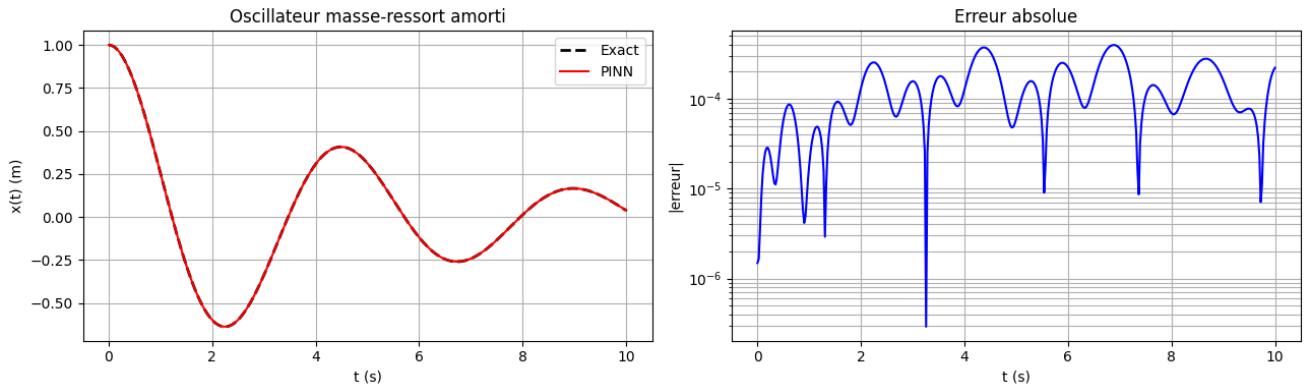


FIGURE 2 – oscillateur masse-ressort amorti ($m = 1$ kg, $k = 2$ N/m, $c = 0{,}4$ N·s/m, $\zeta \approx 0{,}141$). (1 : déplacement $x(t)$. 2 : erreur absolue.)

3.3 Modèle épidémiologique SIR

Le modèle SIR est un modèle compartimental qui décrit la propagation d'une maladie infectueuse dans une population. Nous avons les compartiments :

— $S(t)$: Nombre de **Susceptibles** (personnes non infectées)

— $I(t)$: Nombre d'**Infectés** (personnes malades et contagieuses)

— $R(t)$: Nombre de **Guéris** (personnes immunisées ou décédées)

avec

$$N = S(t) + I(t) + R(t) = \text{constante} \tag{48}$$

Hypothèses :

— Pas de naissances ni de décès naturels

— Mélange homogène de la population

— Immunité permanente après guérison

Paramètres

— β : Taux de transmission (probabilité de contact × probabilité d'infection)

— γ : Taux de guérison ($1/\gamma$ = durée moyenne d'infection)

Nombre de reproduction de base

$$R_0 = \frac{\beta}{\gamma} \tag{49}$$

— $R_0 < 1$: L'épidémie s'éteint

— $R_0 > 1$: L'épidémie se propage

Conditions initiales
À $t = 0$:

$$S(0) = S_0 \quad \text{(proche de } N\text{)} \tag{50}$$
$$I(0) = I_0 \quad \text{(petit, quelques infectés initiaux)} \tag{51}$$
$$R(0) = 0 \quad \text{(personne de guéri au début)} \tag{52}$$

3.3.1 Équations du modèle SIR

Système d'EDO

$$\frac{dS}{dt} = -\beta \frac{SI}{N} \tag{53}$$
$$\frac{dI}{dt} = \beta \frac{SI}{N} - \gamma I \tag{54}$$
$$\frac{dR}{dt} = \gamma I \tag{55}$$

Normalisation
On pose :

$$s(t) = \frac{S(t)}{N}, \quad i(t) = \frac{I(t)}{N}, \quad r(t) = \frac{R(t)}{N} \tag{56}$$

avec $s + i + r = 1$. On a :

$$\frac{ds}{dt} = -\beta si \tag{57}$$
$$\frac{di}{dt} = \beta si - \gamma i \tag{58}$$
$$\frac{dr}{dt} = \gamma i \tag{59}$$

Propriétés du système
Conservation :

$$\frac{d}{dt}(s + i + r) = \frac{ds}{dt} + \frac{di}{dt} + \frac{dr}{dt} = -\beta si + (\beta si - \gamma i) + \gamma i = 0 \tag{60}$$

Donc : $s(t) + i(t) + r(t) = 1$ pour tout t.
Monotonie :

— $s(t)$ est décroissant : $\frac{ds}{dt} \leq 0$
— $r(t)$ est croissant : $\frac{dr}{dt} \geq 0$

Seuil épidémique :
L'épidémie croît ($\frac{di}{dt} > 0$) si et seulement si :

$$s > \frac{\gamma}{\beta} = \frac{1}{R_0} \tag{61}$$

3.3.2 Construction du PINN

Entrée : $t \in [0, T_{max}]$
Sortie : $\begin{pmatrix} \hat{s}(t;\theta) \\ \hat{i}(t;\theta) \\ \hat{r}(t;\theta) \end{pmatrix}$
Dérivées (calculées par différentiation automatique) :

$$\frac{d\hat{s}}{dt}, \quad \frac{d\hat{i}}{dt}, \quad \frac{d\hat{r}}{dt} \tag{62}$$

Perte physique
Résidus :

$$r_s(t_i) = \frac{d\hat{s}}{dt}(t_i;\theta) + \beta \hat{s}(t_i)\hat{i}(t_i) \tag{63}$$
$$r_i(t_i) = \frac{d\hat{i}}{dt}(t_i;\theta) - \beta \hat{s}(t_i)\hat{i}(t_i) + \gamma \hat{i}(t_i) \tag{64}$$
$$r_r(t_i) = \frac{d\hat{r}}{dt}(t_i;\theta) - \gamma \hat{i}(t_i) \tag{65}$$

$$\mathcal{L}_{physics}(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} \left[r_s^2(t_i) + r_i^2(t_i) + r_r^2(t_i) \right] \tag{66}$$

Perte sur les conditions initiales

$$\mathcal{L}_{ic}(\theta) = [\hat{s}(0;\theta) - s_0]^2 + \left[\hat{i}(0;\theta) - i_0 \right]^2 + [\hat{r}(0;\theta) - 0]^2 \tag{67}$$

Perte sur la conservation
Pour renforcer la contrainte $s + i + r = 1$:

$$\mathcal{L}_{cons}(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} \left[\hat{s}(t_i) + \hat{i}(t_i) + \hat{r}(t_i) - 1 \right]^2 \tag{68}$$

Perte totale

$$\mathcal{L}(\theta) = \lambda_{phys} \cdot \mathcal{L}_{physics}(\theta) + \lambda_{ic} \cdot \mathcal{L}_{ic}(\theta) + \lambda_{cons} \cdot \mathcal{L}_{cons}(\theta) \tag{69}$$

$$\theta^* = \min_{\theta} \mathcal{L}(\theta) \tag{70}$$

3.3.3 Implémentation et résultats

Les paramètres épidémiologiques sont $N = 2500$, $S_0 = 2490$, $I_0 = 10$, $R_0 = 0$, $\beta = 0{,}3\ \text{j}^{-1}$ et $\gamma = 0{,}1\ \text{j}^{-1}$, avec un horizon temporel $t \in [0, 100]$ jours. L'entraînement utilise l'optimiseur Adam ($\alpha_0 = 10^{-3}$, décroissance CosineAnnealing, $\eta_{\min} = 10^{-5}$), sur trois budgets de 1000, 2000 et 3000 itérations. Les coefficients de pondération sont $\lambda_{\text{cons}} = 5{,}0$ et $\lambda_{\text{data}} = 50{,}0$.

Remarque importante : contrairement à l'hypothèse initiale d'un PINN purement "physics-only", cette implémentation inclut un terme $\mathcal{L}_{\text{data}}$ (ancrage sur une référence numérique RK45) afin de stabiliser l'apprentissage SIR.

Hyperparamètre	**Valeur**	**Description**
Couches cachées	4	nombre de couches
Neurones/couche	64	largeur du réseau
Activation	Tanh	
N_{col}	400	points de collocation (ODE)
N_{data}	150	points d'ancrage RK45
α_0	10^{-3}	taux d'apprentissage initial
Planificateur	CosineAnnealingLR	$\eta_{\min} = 10^{-5}$
Itérations	1000/2000/3000	
λ_{cons}	5,0	poids conservation
λ_{data}	50,0	poids ancrage données

TABLE 3 – Hyperparamètres du PINN

La figure 3 compare les compartiments prédits par le PINN à la référence RK45, ainsi que l'erreur absolue et la convergence de la loss. Le modèle reproduit correctement la dynamique SIR (décroissance de S, pic de I, croissance de R) sur toute la fenêtre temporelle. Les métriques finales (run à 3000 itérations) sont : $|S + I + R - N|_{\max} = 4{,}21$ individus, $|\Delta S|_{\max} = 3{,}47$ individus, $|\Delta I|_{\max} = 7{,}33$ individus, $|\Delta R|_{\max} = 1{,}83$ individus.

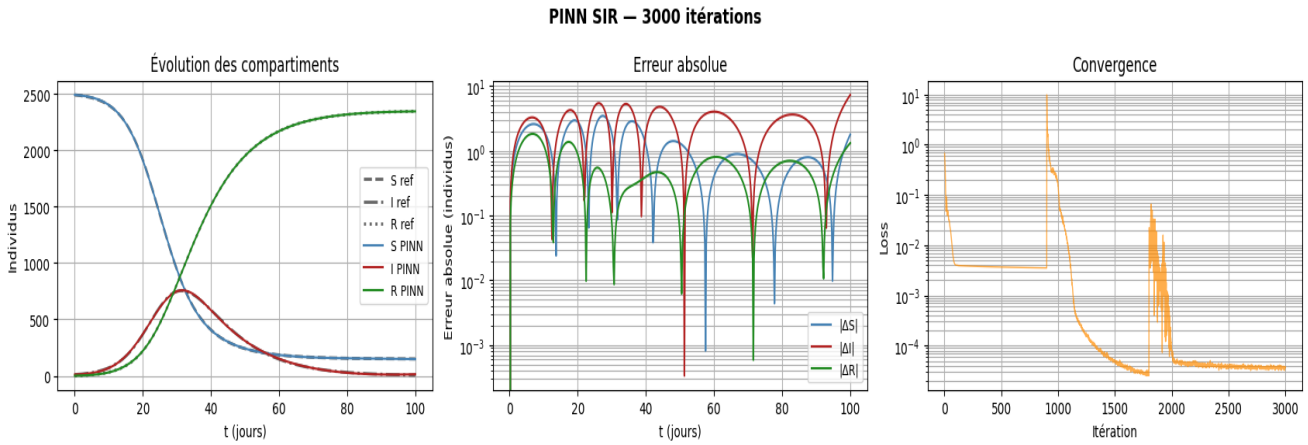


FIGURE 3 – SIR (1. Évolution des compartiments S, I, R vs référence RK45. 2. Erreurs absolues $|\Delta S|$, $|\Delta I|$, $|\Delta R|$. 3. Courbe de convergence de la loss.)

4 Conclusion

Les PINNs permettent d'améliorer les performances de réseaux neuronaux en leur intégrant la physique du phénomène étudier. Ce travail a permis de comprendre les PINNs et de les appliquer dans la résolution d'équations différentielles.

Références

[1] Raissi, M., Perdikaris, P., & Karniadakis, G. E. (2019). *Physics-informed neural networks : A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*. Journal of Computational Physics, 378, 686–707. https://doi.org/10.1016/j.jcp.2018.10.045

[2] Karniadakis, G. E., Kevrekidis, I. G., Lu, L., Perdikaris, P., Wang, S., & Yang, L. (2021). *Physics-informed machine learning*. Nature Reviews Physics, 3, 422–440. https://doi.org/10.1038/s42254-021-00314-5

[3] Lagaris, I. E., Likas, A., & Fotiadis, D. I. (1998). *Artificial neural networks for solving ordinary and partial differential equations*. IEEE Transactions on Neural Networks, 9(5), 987–1000. https://doi.org/10.1109/72.712178

[4] Kermack, W. O., & McKendrick, A. G. (1927). *A contribution to the mathematical theory of epidemics*. Proceedings of the Royal Society A, 115(772), 700–721. https://doi.org/10.1098/rspa.1927.0118

[5] Hethcote, H. W. (2000). *The mathematics of infectious diseases*. SIAM Review, 42(4), 599–653. https://doi.org/10.1137/S0036144500371907

[6] Mamlankou, C. Z. J. (2024). *SIR model : Markovian Approach, Finite Difference Method, PINNs (Physics-Informed Neural Networks)*. Preprint, HAL Id : hal-04855571. https://hal.science/hal-04855571v1